Sesión 9

Data Warehousing, Pipelines y Procesamiento

Carlos César Sánchez Coronel

BASES DE DATOS

Contenido general

1. Introducción
2. Fundamentos de Almacenamiento Analítico
3. Procesos ETL vs ELT
4. Procesamiento Batch vs Streaming
5. Técnicas de Carga Incremental
6. Capas en un Data Warehouse
7. Metadatos y Gobernanza
8. Integración con BI
9. Dimensionamiento de Almacenamiento
10. Arquitecturas Híbridas
11. Pipelines, Jobs y Orquestación
12. Ejercicios Resueltos
13. Glosario

Contenido de la sección

1. Introducción
2. Fundamentos de Almacenamiento Analítico
3. Procesos ETL vs ELT
4. Procesamiento Batch vs Streaming
5. Técnicas de Carga Incremental
6. Capas en un Data Warehouse
7. Metadatos y Gobernanza
8. Integración con BI
9. Dimensionamiento de Almacenamiento
10. Arquitecturas Híbridas
11. Pipelines, Jobs y Orquestación
12. Ejercicios Resueltos
13. Glosario

Objetivos de la sesión

- Definir y diferenciar Data Warehouse, Data Mart, Data Lake y Lakehouse.
- Comprender los procesos ETL y ELT, sus diferencias y cuándo aplicarlos.
- Distinguir entre procesamiento batch y streaming (Lambda y Kappa).
- Conocer técnicas de carga incremental (watermarks, CDC, MERGE).
- Identificar las capas típicas en un data warehouse (raw, staging, core, data marts).
- Entender el papel de los metadatos y la gobernanza.
- Explorar la integración con herramientas de BI y costos asociados.
- Analizar arquitecturas híbridas (SQL + NoSQL).
- Definir pipelines, jobs y orquestación (Airflow).

Contenido de la sección

1. Introducción
2. Fundamentos de Almacenamiento Analítico
3. Procesos ETL vs ELT
4. Procesamiento Batch vs Streaming
5. Técnicas de Carga Incremental
6. Capas en un Data Warehouse
7. Metadatos y Gobernanza
8. Integración con BI
9. Dimensionamiento de Almacenamiento
10. Arquitecturas Híbridas
11. Pipelines, Jobs y Orquestación
12. Ejercicios Resueltos
13. Glosario

Data Warehouse (DW)

Características

- **Orientado a temas**: ventas, clientes, productos.
- **Integrado**: datos de múltiples fuentes unificados.
- **No volátil**: una vez cargados, no se modifican.
- **Histórico**: series temporales para tendencias.

Ejemplos

Amazon Redshift, Google BigQuery, Snowflake, SQL Server DW.

Data Mart

- Subconjunto del DW orientado a un área de negocio específica (ventas, marketing).
- Puede ser **dependiente** (se alimenta del DW) o **independiente** (fuente propia).

Data Lake

Repositorio de datos en bruto

- Almacena cualquier formato: estructurado, semiestructurado, no estructurado.
- Bajo costo (S3, HDFS).
- **Schema-on-read**: el esquema se aplica al leer.
- Ideal para exploración y ciencia de datos.

Lakehouse

Fusión de Data Lake y Data Warehouse

- Datos en formato abierto (Parquet).
- Transacciones ACID, evolución de esquema.
- Rendimiento analítico similar al DW.

Tecnologías

Delta Lake (Databricks), Apache Iceberg, Apache Hudi.

Característica	DW	Data Lake	Lakehouse
Formato de datos	Estructurado	Cualquier formato	Abierto (Parquet)
Esquema	Fijo (schema-on-write)	Flexible (schema-on-read)	Evolutivo
Transacciones ACID	Sí	Limitado	Sí
Rendimiento analítico	Alto	Bajo/Medio	Alto
Costo	Alto	Bajo	Medio

Contenido de la sección

1. Introducción
2. Fundamentos de Almacenamiento Analítico
3. Procesos ETL vs ELT
4. Procesamiento Batch vs Streaming
5. Técnicas de Carga Incremental
6. Capas en un Data Warehouse
7. Metadatos y Gobernanza
8. Integración con BI
9. Dimensionamiento de Almacenamiento
10. Arquitecturas Híbridas
11. Pipelines, Jobs y Orquestación
12. Ejercicios Resueltos
13. Glosario

ETL (Extract, Transform, Load)

- **Ventajas**: control total, menor carga en el DW, adecuado para datos sensibles.
- **Desventajas**: infraestructura adicional, mayor latencia.

ELT (Extract, Load, Transform)

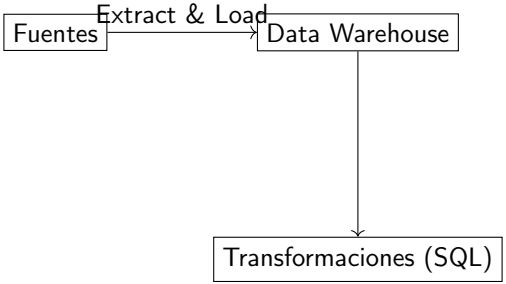

- **Ventajas**: simplicidad, aprovecha escalabilidad del DW, datos crudos disponibles rápidamente.
- **Desventajas**: costo de cómputo en el DW, no ideal para no estructurados.

¿Cuándo usar cada uno?

ETL

- Transformaciones muy complejas o datos sensibles.
- Entornos on-premise.
- Herramientas: Informatica, Talend, Spark batch.

ELT

- DW en la nube (Snowflake, BigQuery, Redshift).
- Agilidad y grandes volúmenes.
- Herramientas: dbt, SQL directo.

Contenido de la sección

1. Introducción
2. Fundamentos de Almacenamiento Analítico
3. Procesos ETL vs ELT
4. Procesamiento Batch vs Streaming
5. Técnicas de Carga Incremental
6. Capas en un Data Warehouse
7. Metadatos y Gobernanza
8. Integración con BI
9. Dimensionamiento de Almacenamiento
10. Arquitecturas Híbridas
11. Pipelines, Jobs y Orquestación
12. Ejercicios Resueltos
13. Glosario

Batch (Lotes)

- Datos acumulados durante un período.
- Ejecución programada (diaria, horaria).
- Herramientas: Apache Spark, Hadoop MapReduce, scripts con cron.
- Casos: facturación mensual, informes de cierre.

Streaming (Tiempo Real)

- Procesamiento continuo de eventos.
- Latencias de milisegundos a segundos.
- Herramientas: Apache Kafka, Apache Flink, Spark Structured Streaming.
- Casos: detección de fraude, monitoreo IoT.

Arquitecturas Lambda y Kappa

Lambda

- Dos capas: batch y speed.
- Precisión batch + baja latencia.
- Compleja de mantener.

Kappa

- Una sola capa de streaming.
- Reprocesamiento como streaming.
- Más simple (requiere motor potente).

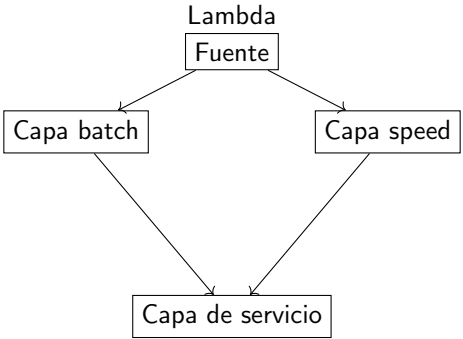

Contenido de la sección

1. Introducción
2. Fundamentos de Almacenamiento Analítico
3. Procesos ETL vs ELT
4. Procesamiento Batch vs Streaming
5. Técnicas de Carga Incremental
6. Capas en un Data Warehouse
7. Metadatos y Gobernanza
8. Integración con BI
9. Dimensionamiento de Almacenamiento
10. Arquitecturas Híbridas
11. Pipelines, Jobs y Orquestación
12. Ejercicios Resueltos
13. Glosario

Marcas de agua (Watermarks)

- Guardar la fecha/hora de la última carga.
- Extraer registros posteriores a esa marca.

Ejemplo SQL

```
- Insertar nuevos datos INSERT INTO dw_v entasSELECT * FROMstg_v entasWHEREfecha > ultima_f echa;
```

Change Data Capture (CDC)

- Captura cambios en tiempo real desde logs de BD.
- Detecta inserciones, actualizaciones, eliminaciones.
- Herramientas: Debezium, AWS DMS, Oracle GoldenGate.

MERGE (UPSERT)

PostgreSQL / SQL Server

```sql
MERGE INTO dw_clientes AS target
USING stg_clientes AS source
ON target.id = source.id
WHEN MATCHED THEN
    UPDATE SET nombre = source.nombre, updated_at = CURRENT_TIMESTAMP
WHEN NOT MATCHED THEN
    INSERT (id, nombre, created_at)
    VALUES (source.id, source.nombre, CURRENT_TIMESTAMP);
```

Contenido de la sección

1. Introducción
2. Fundamentos de Almacenamiento Analítico
3. Procesos ETL vs ELT
4. Procesamiento Batch vs Streaming
5. Técnicas de Carga Incremental
6. Capas en un Data Warehouse
7. Metadatos y Gobernanza
8. Integración con BI
9. Dimensionamiento de Almacenamiento
10. Arquitecturas Híbridas
11. Pipelines, Jobs y Orquestación
12. Ejercicios Resueltos
13. Glosario

Capas típicas

Raw (Bronze) Datos crudos tal como llegan (CSV, JSON). Sirve para reprocesar.

Staging (Silver) Datos limpios, validados, con tipos correctos, sin duplicados.

Core / Integración (Gold) Modelo dimensional (hechos y dimensiones) listo para negocio.

- **Data Marts** Subconjuntos para áreas específicas (ventas, marketing).

Ejemplo de diseño

- **Raw**: archivos JSON de ventas diarias, CSV de productos, logs web.
- **Staging**: tablas temporales con ventas limpias, clientes unificados.
- **Core**: tabla de hechos `ventas`, dimensiones `cliente`, `producto`, `tiempo`.
- **Data Marts**: `ventas_por_region`, `rentabilidad_producto`.

Contenido de la sección

1. Introducción
2. Fundamentos de Almacenamiento Analítico
3. Procesos ETL vs ELT
4. Procesamiento Batch vs Streaming
5. Técnicas de Carga Incremental
6. Capas en un Data Warehouse
7. Metadatos y Gobernanza
8. Integración con BI
9. Dimensionamiento de Almacenamiento
10. Arquitecturas Híbridas
11. Pipelines, Jobs y Orquestación
12. Ejercicios Resueltos
13. Glosario

Tipos de metadatos

Técnicos	Esquemas, tipos de datos, particiones, estadísticas.
De negocio	Definiciones, reglas de cálculo, propietarios.
Operacionales	Logs de ejecución, tiempos de carga.

Herramientas de catálogo y linaje

- Catálogos: Apache Atlas, Amundsen, DataHub, AWS Glue Catalog.
- Linaje: trazabilidad del origen y transformaciones (importante para auditoría y GDPR).

Contenido de la sección

1. Introducción
2. Fundamentos de Almacenamiento Analítico
3. Procesos ETL vs ELT
4. Procesamiento Batch vs Streaming
5. Técnicas de Carga Incremental
6. Capas en un Data Warehouse
7. Metadatos y Gobernanza
8. Integración con BI
9. Dimensionamiento de Almacenamiento
10. Arquitecturas Híbridas
11. Pipelines, Jobs y Orquestación
12. Ejercicios Resueltos
13. Glosario

Conexión a herramientas de visualización

- Power BI, Tableau, Looker, Qlik.
- Modos: **Importación** (datos copiados) vs **DirectQuery** (consultas en vivo).
- Recomendación: usar agregaciones precalculadas y vistas materializadas para rendimiento.

Contenido de la sección

1. Introducción
2. Fundamentos de Almacenamiento Analítico
3. Procesos ETL vs ELT
4. Procesamiento Batch vs Streaming
5. Técnicas de Carga Incremental
6. Capas en un Data Warehouse
7. Metadatos y Gobernanza
8. Integración con BI
9. Dimensionamiento de Almacenamiento
10. Arquitecturas Híbridas
11. Pipelines, Jobs y Orquestación
12. Ejercicios Resueltos
13. Glosario

Factores a considerar

- Volumen diario de datos.
- Retención histórica.
- Compresión (columnar: Parquet, ORC).
- Índices y particionamiento.
- Backups y replicación.

Ejemplo de cálculo

Problema: 500 GB/día, retención 3 años, compresión 4:1, costo S3 $0.023/GB-mes.

- Datos diarios: 500 GB.
- Anual: 500 GB * 365 = 182.5 TB.
- 3 años: 547.5 TB.
- Con compresión 4:1: 136.9 TB.
- Margen 10 %: 150.6 TB.
- Costo mensual: 150.6 * 1024 * 0.023 $3,546/mes.

Contenido de la sección

1. Introducción
2. Fundamentos de Almacenamiento Analítico
3. Procesos ETL vs ELT
4. Procesamiento Batch vs Streaming
5. Técnicas de Carga Incremental
6. Capas en un Data Warehouse
7. Metadatos y Gobernanza
8. Integración con BI
9. Dimensionamiento de Almacenamiento
10. Arquitecturas Híbridas
11. Pipelines, Jobs y Orquestación
12. Ejercicios Resueltos
13. Glosario

Caso de uso combinado

- **PostgreSQL**: transacciones (pedidos).
- **MongoDB**: catálogo de productos flexible.
- **Elasticsearch**: búsqueda rápida.
- **Snowflake**: análisis de ventas.

Sincronización entre motores

- CDC con Debezium desde PostgreSQL a Kafka.
- Consumidores escriben en MongoDB, Elasticsearch y el DW.
- Batch periódico con Apache Spark para reconciliación.

Contenido de la sección

1. Introducción
2. Fundamentos de Almacenamiento Analítico
3. Procesos ETL vs ELT
4. Procesamiento Batch vs Streaming
5. Técnicas de Carga Incremental
6. Capas en un Data Warehouse
7. Metadatos y Gobernanza
8. Integración con BI
9. Dimensionamiento de Almacenamiento
10. Arquitecturas Híbridas
11. Pipelines, Jobs y Orquestación
12. Ejercicios Resueltos
13. Glosario

Definiciones

Pipeline Flujo completo de procesamiento de datos.

Job Unidad de trabajo (puede contener varias tareas).

Tarea Paso individual (script, consulta SQL).

DAG Grafo acíclico dirigido que define dependencias.

Orquestadores populares

- Apache Airflow (el más usado, DAGs en Python).
- Prefect, Dagster (alternativas modernas).
- AWS Step Functions, Google Cloud Composer (gestionados).

Ejemplo de DAG en Airflow

```python
from airflow import DAG
from airflow.operators.python import PythonOperator
from airflow.providers.apache.spark.operators.spark_submit import SparkSubmitOperator
from airflow.providers.amazon.aws.operators.redshift import RedshiftSQLOperator
from datetime import datetime
import requests

def extraer_api():
    response = requests.get('https://api.ejemplo.com/data')
    with open('/tmp/data.json', 'w') as f:
        f.write(response.text)

with DAG('pipeline_ventas', start_date=datetime(2025,1,1), schedule='@daily') as dag:
    extraer = PythonOperator(task_id='extraer', python_callable=extraer_api)
    transformar = SparkSubmitOperator(
        task_id='transformar',
        application='/path/to/spark_job.py',
        conn_id='spark_default'
    )
    cargar = RedshiftSQLOperator(
        task_id='cargar',
        sql='CALL cargar_ventas();',
        redshift_conn_id='redshift_default'
    )
    extraer >> transformar >> cargar
```

Contenido de la sección

1. Introducción
2. Fundamentos de Almacenamiento Analítico
3. Procesos ETL vs ELT
4. Procesamiento Batch vs Streaming
5. Técnicas de Carga Incremental
6. Capas en un Data Warehouse
7. Metadatos y Gobernanza
8. Integración con BI
9. Dimensionamiento de Almacenamiento
10. Arquitecturas Híbridas
11. Pipelines, Jobs y Orquestación
12. Ejercicios Resueltos
13. Glosario

Ejercicio 1: Diseño de capas para un DW de ventas

Enunciado: Proponga un diseño de capas (raw, staging, core) y las transformaciones típicas.

Solución

- **Raw**: Archivos CSV/JSON de ventas, productos, clientes tal como llegan. Particionado por fecha.
- **Staging**: Asignar tipos correctos, eliminar duplicados, unificar formatos de fecha. Guardar en Parquet.
- **Core**: Construir tablas de hechos (ventas) y dimensiones (cliente, producto, tiempo) con modelado dimensional. Aplicar SCD tipo 2.

Ejercicio 2: Carga incremental con MERGE

Enunciado: Escribir una consulta SQL que actualice `dw_ventas` con los datos de `stg_ventas` del día usando MERGE.

Solución

```sql
MERGE INTO dw_ventas AS target
USING stg_ventas AS source
ON target.id = source.id
WHEN MATCHED THEN
    UPDATE SET target.monto = source.monto,
               target.fecha_actualizacion = CURRENT_TIMESTAMP
WHEN NOT MATCHED THEN
    INSERT (id, fecha, monto, fecha_actualizacion)
    VALUES (source.id, source.fecha, source.monto, CURRENT_TIMESTAMP);
```

Ejercicio 3: Estimar costo de almacenamiento

Enunciado: 500 GB/día, retención 3 años, compresión 4:1. Calcular almacenamiento y costo mensual en S3 ($0.023/GB-mes).

Solución

- Datos diarios: 500 GB.
- Anual: 500 * 365 = 182.5 TB.
- 3 años: 547.5 TB.
- Compresión 4:1: 136.9 TB.
- Margen 10 %: 150.6 TB.
- Costo mensual: 150.6 * 1024 * 0.023 $3,546/mes.

Ejercicio 4: Pipeline con Airflow

Enunciado: Crear DAG con tareas: extraer de API, transformar con Spark, cargar en Redshift.

Solución (ver código en sección 11)

(El código del DAG se mostró anteriormente en la diapositiva de Airflow).

Contenido de la sección

1. Introducción
2. Fundamentos de Almacenamiento Analítico
3. Procesos ETL vs ELT
4. Procesamiento Batch vs Streaming
5. Técnicas de Carga Incremental
6. Capas en un Data Warehouse
7. Metadatos y Gobernanza
8. Integración con BI
9. Dimensionamiento de Almacenamiento
10. Arquitecturas Híbridas
11. Pipelines, Jobs y Orquestación
12. Ejercicios Resueltos
13. Glosario

Términos Clave

Batch	Procesamiento por lotes en intervalos.
CDC	Change Data Capture, captura de cambios en tiempo real.
Data Lake	Repositorio de datos en bruto.
Data Mart	Subconjunto del DW para un área específica.
Data Warehouse	Almacén de datos optimizado para análisis.
DAG	Directed Acyclic Graph, dependencias de tareas.
ELT	Extract, Load, Transform (cargar primero, transformar después).
ETL	Extract, Transform, Load (transformar antes de cargar).
Lakehouse	Fusión de data lake y data warehouse.
Linaje	Trazabilidad del origen y transformaciones.
Merge	Operación que inserta o actualiza según exista.
Metadatos	Datos sobre los datos.
Orquestación	Coordinación de tareas en un pipeline.
Pipeline	Flujo completo de procesamiento.
Streaming	Procesamiento continuo en tiempo real.

¡Gracias!